面试必考：B树、B-树、B+树、B*树图文详解

程序员面试 5月20日

以下文章来源于非科班的科班，作者攀牡

B树

B树又叫做二叉搜索树，倒状的树形结构。如下图所示

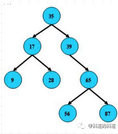

特点：

- 所有的非子夜节点最多拥有两个子节点树（左子树和右子树）。
- 所有结点存储一个关键字。
- 节点的左右儿子，左边是比该节点小的，右边是比该节点大的。

缺点：

因为二叉搜索树不存在平衡算法，所以在某些特殊的情况下，二叉搜索树等同于线性，出现蹩脚的情况，设计者们发现降低树的高度自然就可以提高查找效率。那么如何解决降低树的高度的问题？在这种基础上设计者给二叉树加入了平衡算法，出现了平衡树。

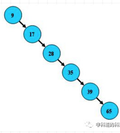

二叉树搜索树的查询原理，先从根节点开始，和根节点匹配，若是比根节点小就进入左子节点，若是比根节点大进行右子节点，依次按照这样的逻辑进行，找到就返回。

> 另一方面树的高度也会影响查询的效率，设计者又是怎么解决的呢？
> 假设大规模数据存储中，实现索引查询这样一个实际背景下，树节点存储的元素数量是有限的，即使存储在平衡二叉树中，在大量数据的储存情况下，这样导致二叉平衡查找树结构由于树的深度过大而造成磁盘I/O读写过于频繁，进而导致查询效率低下，那么如何减少树的深度（当然是不能减少查询的数据量），一个基本的想法就是：采用多叉树结构（由于树节点元素数量是有限的，自然该节点的子树数量也就是有限的）。在这种前提下，B-、B+、B*也就是这样的数据结构，多路搜索树，不再是只有二叉。

所谓的平衡就是加上平衡算法，在B树在经过多次插入与删除后，有可能导致不同的结构，极端一点就是出现线性的蹩脚树，通过平衡算法（左旋和右旋），使树的节点分布均匀，是树的查找算法等同于二分查找。所以对于树而言要提高查找的效率，一个是保存平衡；另一个是减少树的高度。

B-树

基于减少树的高度上，B-树是一种多路搜索树，并不是二叉的。如下图所示：

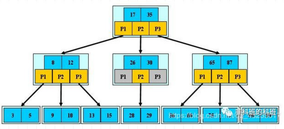

特点：

- 所有的非叶子结点最多有M个儿子（且M>2）。
- 根结点的儿子数为[2, M]，其它非叶子结点的儿子数为[M/2, M]。
- 每个结点存放至少M/2-1（取上整）和至多M-1个关键字；（至少2个关键字）。
- 非叶子结点的关键字个数=指向儿子的指针个数-1。
- 非叶子结点的关键字中从左到右由大到小排序。即A[1]<A[2]<A[3]<....A[k-1]<A[k]。
- 非叶子结点的指针：P[1], P[2], ..., P[M]；其中P[1]指向关键字小于K[1]的子树，其它P[i]指向关键字属于K[i-1], K[i]范围的子树，最后一个指针P[M]指向大于最后一个关键字A[M-1]范围的值。
- 关键字集合分布在整颗树中，并且只会在节点中出现一次。
- 搜索可能在非子叶节点或者子叶节点结束，即非子叶节点也存储数据的身，这个与B+树有根本区别。
- 所有叶子结点位于同一层。

缺点：

- 当数据量大的时候不是依然会查询到最底层的叶子节点。这就是B-树的缺点，但是相比B树而言已经优化了很多。

> B-树的性能总是等价于二分查找（与M值无关），也就没有B树平衡的问题。由于M/2的限制，在插入结点时，如果结点已满，需要将结点分裂为两个各占M/2的结点；删除结点时，需将两个不足M/2的兄弟结点合并。

B+树

B+树是B-树的变体，也是一种多路搜索树。如下图所示：

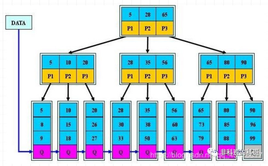

B+基本与B-树同，以下是与B-树的区别：

- 非叶子结点的指针与关键字个数相等，而B-树的关键字=指针个数-1；
- 指针P[i]，指向关键字值属于[K[i], K[i+1])范围的子树，而在B-树是开区间。
- 所有叶子结点增加一个指针，指向下一个的兄弟叶子节点。
- 所有关键字都出现在叶子结点的链表中（稠密索引），且链表中的关键字恰好是有序的，搜索只会在叶子节点结束，叶子节点存储所有关键字的值。
- 不可能在非叶子结点命中；非叶子结点相当于是叶子结点的索引（稀疏索引），叶子结点相当于是存储。

B树与B+树的区别：

- 所有的叶子节点包含了全部关键字信息，及指向含有这些关键字记录的指针，且叶子结点本身依关键字的大小自小而大的顺序链接。(而B树的叶子节点并没有包括全部需要查找的信息)。
- 所有的非终端结点可以看成是索引部分，结点中仅含有其子树根结点中最大（或最小）关键字。(而B树的非终节点也包含需要查找的有效信息)。

> 这些链指针在链表中是有序存储的，在搜索中能省大量的时间。那这些链指针可不可以加在所有的节点中呢，答案是可以的，除了根节点，所有的节点都可以加上链指针。这就是B*树索引。

B*树

B*树是在B+树的基础上，在B+树的非根和非叶子结点增加指向兄弟的指针，将结点的最低利用率从1/2提高到2/3。

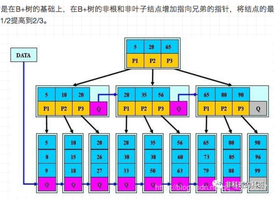

特点：

- B*树定义了非叶子结点关键字个数至少为(2/3)M，即块的最低使用率为2/3（代替B+树的1/2）
- 在非根和非叶子结点增加指向兄弟的指针。

> B+树与B*树的区别：
> （1）B+树的分裂：当一个结点满时，分配一个新的结点，并将原结点中1/2的数据复制到新结点，最后在父结点中增加新结点的指针；B+树的分裂只影响原结点和父结点，而不会影响兄弟结点，所以它不需要指向兄弟的指针。
> （2）B*树的分裂：当一个结点满时，如果它的下一个兄弟结点未满，那么将一部分数据移到兄弟结点中，再在原结点插入关键字，最后修改父结点中兄弟结点的关键字（因为兄弟结点的关键字范围改变了）；如果兄弟也满了，则在原结点与兄弟结点之间增加新结点，并各复制1/3的数据到新结点，最后在父结点增加新结点的指针。
> 结论：
> 所以，B*树分配新结点的概率比B+树要低，空间使用率更高。

关于回表查询：

比如select name from table where id=7，如果name没有索引，那在查询的时候先得得到的是id对应这条数据所在的行数。拿着这个行数，再去表中查询这条数据，得到name字段。而拿着这个行数去得到name字段的动作，就是回表查询。

我们如何避免回表查询呢，首先就是不要用 " * " 查询，因为这时候会默认查询的字段没有索引，必定进行回表查询。